Lab1-实验报告

钟溯陬 PB18111764

单航 PB18111747

代码描述

`tokenization_opt.py`

这个代码在utils文件夹里，读取path文件，用来生成倒排表（前一千）

1. 首先利用正则化过滤文件（邮件头部，邮箱地址，URL，HTML标签），减小分词工作量以及优化索引效果
2. 接着迭代读取每个文档(try打不开的就不管他了，视为空)，进行如下操作：
3. 使用nltk包进行分词，去停用词，使用SnowballStemmer进行词根化，存到同名文件中
    - 在一开始并没有选择将其存储，但考虑到建立矩阵时还需要用到，为了保证一致性便选择存储。
4. 直接进行倒排索引的构建，把索引看成是一个字典<token, [docID, docID2, ...]>，对每个词进行遍历：
    - 若某词项有对应key，则看对应列表的最后一个有无该词[优化]，没有则append进去
    - 若某词项没有，则给该词项建立初始为此时的docID的列表项
5. 输出倒排表为index.txt，在迭代时，将其输出为间距格式[优化]，同时还输出df.txt即词项的df值。

`bool_search.py`

这个代码在src文件夹中，获取Bool查询的输入，用来输出符合规则的相应文档：

1. 首先是arg_parse获取输入，以下是一开始的蠢想法：

    > 考虑到群里的要求，需要做一个语义分析。
    > ~~根据，OR，AND，NOT由低到高的优先级，一个bool检索可写成如下文法。~~
    > $E \rightarrow E\ \mathbf{OR}\ T \mid T;\quad T \rightarrow T\mathbf{AND}F \mid F;\quad F \rightarrow \mathbf{NOT}\ F \mid (E) \mid \mathbf{token}$
    > 最后发现，将布尔表达式的中缀式换成后缀式即可

    以上的实现写在`parse_query()`中

2. 其中，函数意义分别如下：
    - `parse_query()`用来将表达式正则化，词根化，并转化为后缀式，以列表的形式存储。
    - `load_index()`从倒排文件中，找到相对应的词项及其文档表，以列表的形式返回
        - 直接遍历获取，没什么说的
        - 把间距变回正常序号
    - `bool_AND(),bool_OR(),bool_NOT()`分别是三个不同操作符的实现
        - AND是一个个比对，保留相同的。使用书上的合并算法（没有跳表指针，因为没要求（（（

        - OR是一个个比对，有就留下来，注意一个表遍历完了还要继续遍历没完的。
        - NOT是直接对这个表求反，即返回所有DOC集合没有这个文档的
    - `search()`是对`parse_query()`得到的操作符和词项，存入栈中，进行操作，并返回bool查询的最终结果
        - 即是后缀表达式的计算规则
        - 迭代输入，如果是词项，放进栈中；如果是AND或OR，则对栈头两个元素操作，结果放回栈里；如果是NOT，则只对一个元素进行操作。知道遍历完输入，吐出栈底元素。
3. 通过`search()`获得的即为文档列表，并对其包装，输出
    - 第一行是原表达式的输出
    - 第二行是表达式在栈中的后缀表达式形式
    - 第三行往后是提示在第几个倒排项找到了某个词
    - 以及布尔查询结果的输出(通常很长)，如图及索引结果验证

exp1 > output > bool_debug.log

```
power&businessORenergy & natural AND signed
['power', 'busi', '&', 'energi', 'natur', 'sign', '&', '&', '|']
power
successfully find power in invert index No 3 !
busi
successfully find busi in invert index No 34 !
energi
successfully find energi in invert index No 4 !
natur
successfully find natur in invert index No 188 !
sign
successfully find sign in invert index No 239 !


result is docID = 16 which is maildir/arnold-j/notes_inbox/67.

result is docID = 23 which is maildir/arnold-j/notes_inbox/45.

result is docID = 50 which is maildir/arnold-j/notes_inbox/56.

```

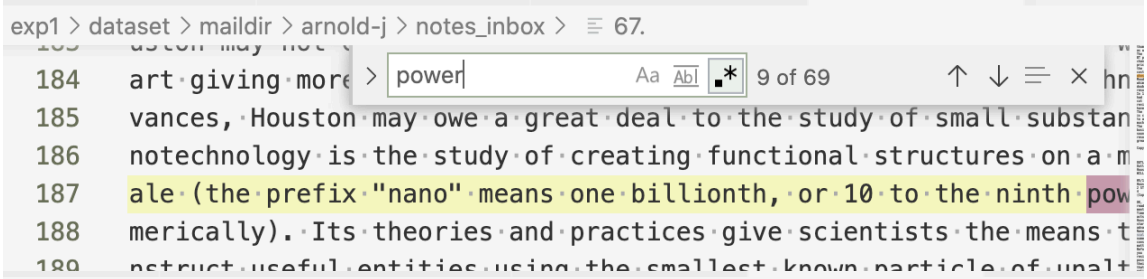

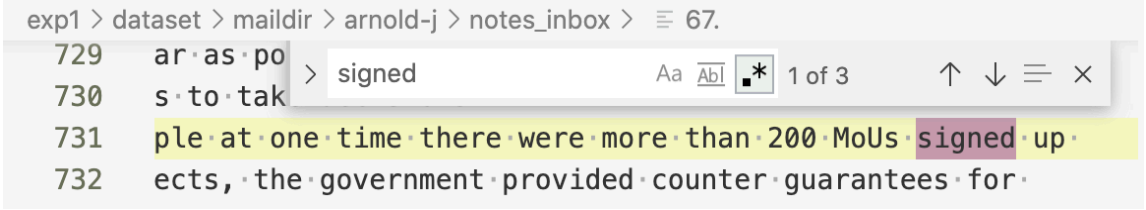

`matrix.py`

代码在utils文件夹里，用来生成tf-idf矩阵

1. 首先获取文档数目，然后打开df.txt读取词项-DF对，并计算idf
2. 遍历之前存储的分词后的文档，存储tf值。
3. 根据tf-idf公式$W_{t,d} = (1 + \log tf_{t,d}) \cdot \log N/df_t$，循环填入矩阵
4. 使用`scipy.sparse.csr_matrix`按行压缩并使用save_npz存储

`semantic_search.py`

代码在src文件夹里，用来计算相似度并排序

1. 老样子使用argparse来获取参数输入，并用`sparse.load_npz`读取压缩文件（很耗时）
    - 打印了`head()`，可以看到tf-idf的大概样子
2. 使用`split()`和词根化获取输入，并根据token位置存成向量的形式
3. 使用余弦相似度对查询向量与tf-idf向量迭代进行运算，并将结果存放在`result`里面
4. 使用pandas进行排序，并包装结果进行输出：

使用查询“The president plans to be a power and energy company” 结果如图：

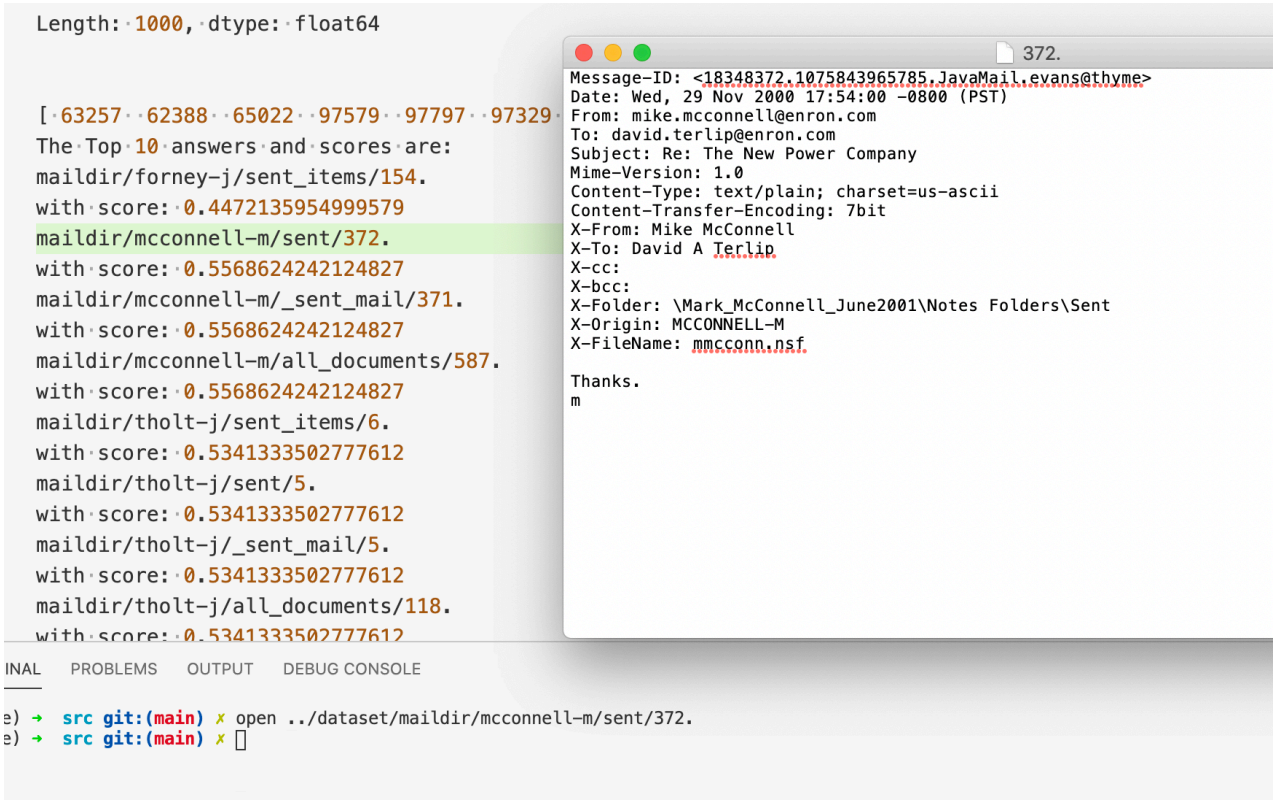

结果优化

1.索引的时空复杂度的优化

时间优化： 之前用以下python式语句判断是否添加倒排表词项：

```
if docID not in invertIndex[token]:
```

这导致时间复杂度与文档数量不成线性关系，是$O(n^2)$的，输出小规模的耗时如图及拟合图：

```
total docs = 10000
total time = 27.230363845825195
index time = 3.009058952331543
reTime = 3.4250636100769043
stopTime = 0
stemTime = 20.05732035636902
```

```
total docs = 20000
total time = 80.02519822120667
index time = 15.990978956222534
reTime = 8.767294645309448
stopTime = 0
stemTime = 47.34056520462036
```

```
total docs = 30000
total time = 146.12736988067627
index time = 40.184300899505615
reTime = 14.366731882095337
stopTime = 0
stemTime = 78.54025053977966
```

```
total docs = 40000
total time = 216.53626799583435
index time = 74.12460947036743
reTime = 19.39746117591858
stopTime = 0
stemTime = 103.91469812393188
```

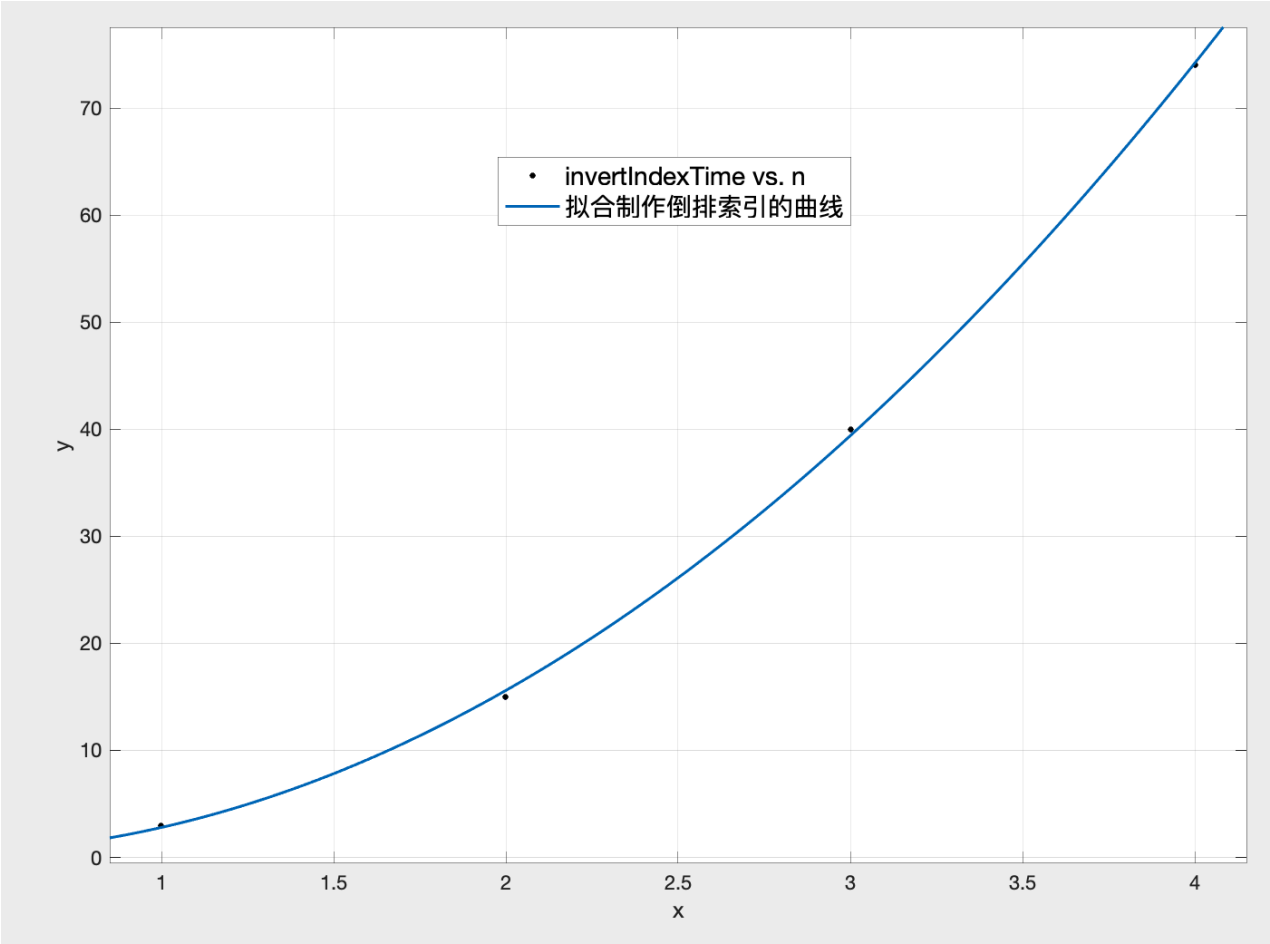

这导致若是大规模进行生成，需要数小时，很不现实。于是做了一个修改：

```
if invertIndex[token][-1] != docID :
```

这就使得时间大幅降低：

原：

```
total docs = 40000
total time = 216.53626799583435
index time = 74.12460947036743
reTime = 19.39746117591858
stopTime = 0
stemTime = 103.91469812393188
```

改进：

```
total docs = 40000
total time = 131.87948274612427
index time = 4.242624044418335
reTime = 18.004252910614014
stopTime = 0
stemTime = 97.88430166244507
```

最终耗时(s)为 `total time = 2104.855010986328` ，（若存储分词结果则为 `2743.555778026581` ）

空间优化：

与讲义不同，并不是读取所有文档后再进行建立索引，那样至少会占用所有文档大小的内存。本实验采用迭代文档分别进行分词，词根化，添加进倒排表的操作。并对其进行了如上的时间优化。

存储也做了优化：在一开始，输出，即保存倒排表，这里用了很蠢的方法，即直接保留ID：

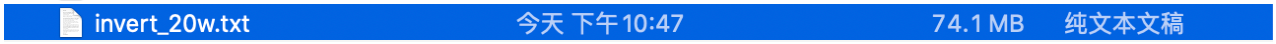

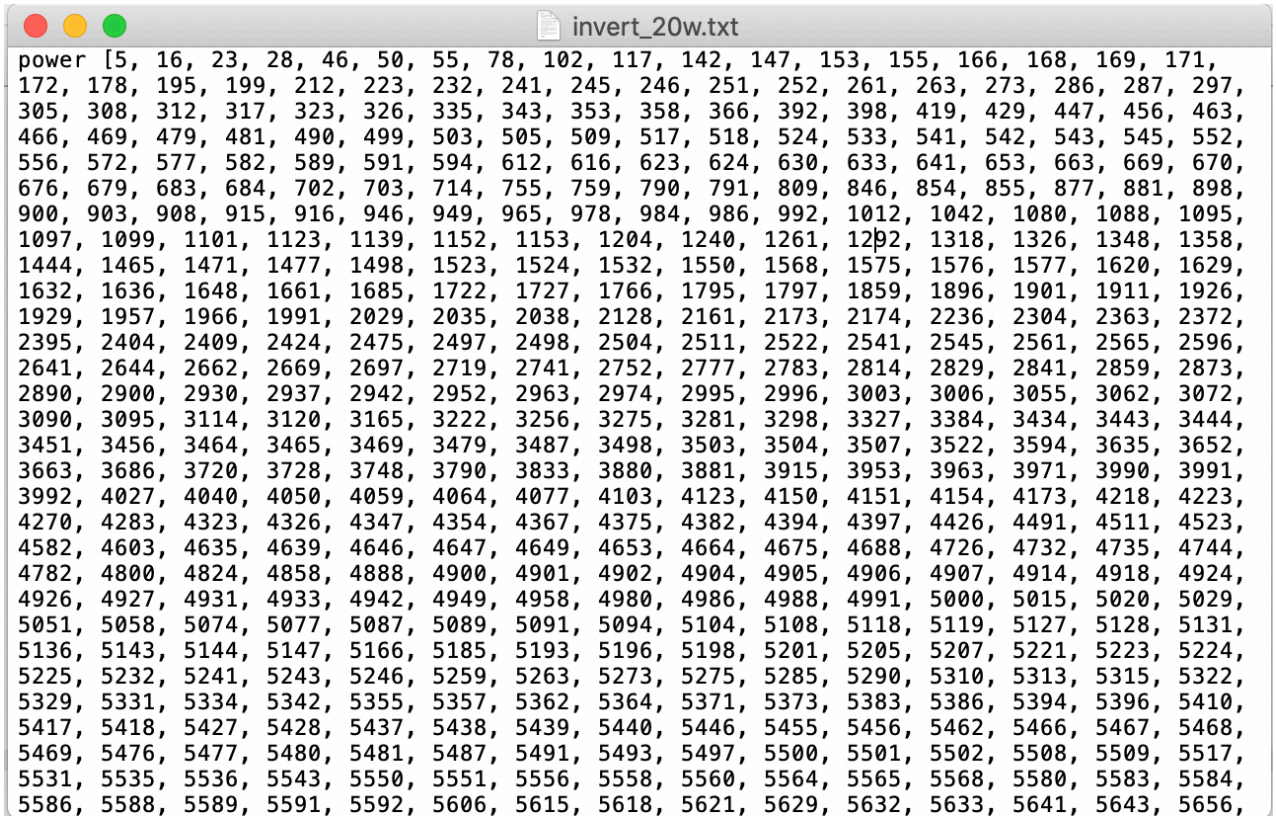

可以看到才20w就已经74MB了，所以才用了存储间距的方法：最后50w文档生成的大小为：

以上。

Speed-UP

（以下东西助教看看就好。。。）

除了python程序，因另一门课的要求（，还做了一个CUDA C程序，即用显卡加速。效果很好。和Python程序跑出了一样差不多的结果（应该是哪里有bug，但这不是这次实验的要求（懒得改了））。反正速度很快。

程序获取输入是TF表的COO压缩格式，和idf表，默认一个输入是python文件中的默认查询词。输出如下。

```
[zsy@new-node2 pc]$ ./tf_idf
Copy input data from the host memory to the CUDA device
begin calc
begin transfer
begin transepose
begin mult
The top 10 scores are
0.556862 0.556862 0.556862 0.447214 0.447214 0.447214 0.447214 0.447214 0.447214 0.447214
And the total time is 7 s
[zsy@new-node2 pc]$
```

源代码放在了utils文件夹中。使用时需要先使用matrix.py，（去掉一些注释）生成tfidf_coo.txt文件和idf.txt文件。然后在命令行进行编译，执行。(需要有CUDA环境)

```
> nvcc -lsparse tf_idf.cu -o tfidf
> ./tf_idf
```